В файлах TrainData.csv и TestData.csv находятся данные о клиентах некоторой компании.

В этом задании предлагается изучить анонимизированные характеристики клиентов и на их основе решить задачу оттока: понять, покинет клиент компанию или нет.

Описание столбцов:

* столбцы 0-13 - анонимизированная информация о клиентах

* столбец target - целевая переменная: 1 - клиент покинет компанию, 0 - не покинет

Задания:

1. Считайте данные в два pandas dataframe: df_train и df_test.
Проверьте, есть ли в тренировочных и в тестовых данных пропуски? Укажите количество столбцов тренировочной выборки, имеющих пропуски.

Ответ:

2. В столбце с наибольшим количеством пропусков заполните пропуски средним значением по столбцу. В ответ запишите значение вычисленного среднего.

Ответ:
3. Найдите строки в тренировочных данных, где пропуски стоят в столбце с наименьшим количеством пропусков. Удалите эти строки. Сколько строк вы удалили?
Ответ:

4. Переведите столбец с целевой переменной в бинарные значения по правилу: Churn - 1, Not churn - 0. Исправьте опечатки в названиях категорий целевой переменной (до того, как переводить их в бинарные значения).

Сколько опечаток вы исправили?
Ответ:

В этом задании все пункты выполняйте только по таблице df_train.

5. Сколько столбцов в таблице (не считая target) содержат меньше 5 различных значений?

Ответ:

6. Верно ли, что если значение единственного категориального признака в таблице равно A, то клиент уйдет из компании? (target = 1) В ответ запишите “да” или “нет” без кавычек.
Ответ:

7. Вычислите долю ушедших из компании клиентов, для которых значение признака 2 больше среднего значения по столбцу, а значение признака 13 меньше медианы по столбцу. Ответ округлите до сотых. Считайте долю ушедших только среди ушедших (Churn = 1).
Ответ:

8. Разбейте тренировочные данные на целевой вектор y, содержащий значения из столбца target, и матрицу объект-признак X, содержащую остальные признаки. Обучите на этих

данных логистическую регрессию из sklearn (LogisticRegression) с параметрами по умолчанию. Выведите среднее значение метрики f1-score алгоритма на кросс-валидации с тремя фолдами. Ответ округлите до сотых.

Ответ:

При объявлении модели фиксируйте random_state = 42.

Комментарий: параметры по умолчанию предполагаются следующими
penalty='l2', dual=False, tol=0.0001, C=1.0, fit_intercept=True, intercept_scaling=1, class_weight=None, solver='lbfgs', max_iter=100, multi_class='auto', verbose=0, warm_start=False, n_jobs=None, l1_ratio=None

9. Подберите значение константы регуляризации C в логистической регрессии, перебирая гиперпараметр от 0.001 до 100 включительно, проходя по степеням 10. Для выбора C примените перебор по сетке по тренировочной выборке (GridSearchCV из библиотеки sklearn.model_selection) с тремя фолдами и метрикой качества - f1-score. Остальные параметры оставьте по умолчанию. В ответ запишите наилучшее среди искомых значение C.
При объявлении модели фиксируйте random_state = 42.

Ответ:

Комментарий: параметры по умолчанию предполагаются следующими

penalty='l2', dual=False, tol=0.0001, fit_intercept=True, intercept_scaling=1, class_weight=None, solver='lbfgs', max_iter=100, multi_class='auto', verbose=0, warm_start=False, n_jobs=None, l1_ratio=None

10. Добавьте в тренировочные и тестовые данные новый признак ‘NEW’, равный произведению признаков ‘7’ и ‘11’.

На тренировочных данных с новым признаком заново с помощью GridSearchCV (с тремя фолдами и метрикой качества - f1-score) подберите оптимальное значение C (перебирайте те же значения C, что и в предыдущих заданиях), в ответ напишите наилучшее качество алгоритма (по метрике f1-score), ответ округлите до сотых.

При объявлении модели фиксируйте random_state = 42.

Ответ:

Комментарий: параметры по умолчанию предполагаются следующими

penalty='l2', dual=False, tol=0.0001, fit_intercept=True, intercept_scaling=1, class_weight=None, solver='lbfgs', max_iter=100, multi_class='auto', verbose=0, warm_start=False, n_jobs=None, l1_ratio=None

11. Теперь вы можете использовать любую модель машинного обучения для решения задачи. Также можете делать любую другую обработку признаков. Ваша задача - получить наилучшее качество по метрике accuracy на тестовых данных.

Качество проверяется на представленных тестовых данных.

Цель - accuracy >= 0.9