Датасет содержит информацию о различных хлопьях. Вам необходимо провести анализ данных, а также научиться прогнозировать рейтинг хлопьев по их характеристикам.

Признаки, которые содержатся в данных:

- mfr - производитель хлопьев
  - A = American Home Food Products;
  - G = General Mills
  - K = Kelloggs
  - N = Nabisco
  - P = Post
  - Q = Quaker Oats
  - R = Ralston Purina
- **fat**: количество граммов жира
- **sodium**: количество миллиграммов натрия
- **fiber**: количество граммов диетических волокон
- **carbo**: количество граммов сложных углеводов
- **potass**: количество миллиграммов калия
- **vitamins**: процент содержания витаминов и минералов от рекомендуемой дневной нормы
- **shelf**: на какой по счету (считая от пола) полке стоят хлопья
- **weight**: вес одной упаковки в унциях
- **cups**: число порций в одной упаковке
- **rating**: рейтинг хлопьев (целевая переменная).

Считайте данные в pandas dataframe и выполните задания.

1) Сколько в dataframe числовых столбцов?
2) Вычислите средний рейтинг всех хлопьев. Ответ округлите до сотых.
3) Сколько хлопьев стоят на второй полке?
4) На сколько единиц различается средний рейтинг хлопьев, стоящих на первой и на второй полке? Ответ округлите до целого числа.
5) Вычислите 25%-ю квантиль рейтинга хлопьев, стоящих на второй полке, а также содержащих более 50 миллиграммов калия.
Используйте функцию numpy.percentile с параметрами method='linear',
6) Разбейте dataframe на признаки x и целевую переменную y.

7) Закодируйте категориальный столбец mfr при помощи метода One Hot Encoding, исключите мульколлинеарность. Три самых редких категорий ДО кодировки объедините в одну - “other”.

8) Сколько столбцов стало в итоговом датасете после применения One Hot Encoding?

9) Добавьте в датасет новый признак new равный произведению признаков **weight и cups.**

10) Разбейте полученный датасет на множества train и test с помощью функции train_test_split() в отношении 90% к 10%. Теперь при помощи кросс-валидации с пятью фолдами обучите решающее дерево глубины 3 (**DecisionTreeRegressor** из билиотеки **sklearn.tree)** с random_state=42 и другими гиперпараметрами по умолчанию на train и выведите среднее значение метрики **r2_score**. Ответ округлите до сотых.

Комментарий: *гиперпараметры DecisionTreeClassifier по умолчанию (criterion='squared_error', splitter='best', min_samples_split=2, min_samples_leaf=1, min_weight_fraction_leaf=0.0, max_features=None, max_leaf_nodes=None, min_impurity_decrease=0.0, ccp_alpha=0.0, monotonic_cst=None)*

11) Подберите гиперпараметр 'criterion' на множестве train, используя GridSearch с 5ю фолдами и метрикой качества r2:

'criterion' : [“squared_error”, “friedman_mse”, “absolute_error”, “poisson”]

В ответе напишите среднее качество на кросс-валидации у лучшего найденного алгоритма. Ответ округлите до сотых.

12) Теперь вы можете использовать любую модель машинного обучения для решения задачи. Также можете делать любую другую обработку признаков. Ваша задача - получить наилучшее качество (**r2**).

Для проверки качества

Вычислите r2 на тестовом множестве.

цель: r2 > 0.8